

LAPORAN

Analisis Big Data Membaca Tren Pasar Modal di Tengah Gelombang Otomatisasi AI

Mata Kuliah : Big Data

Dosen Pengampu : Dr. CHAERUR ROZIKIN, S.Kom., M.Kom



Dibuat Oleh :

RAHMAT FITRAH	: 20240040104
RAISSA CALLISTA AULIA	: 20240040048
SALSA RIZKY SABILLAH	: 20240040195

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK KOMPUTER DAN DESAIN NUSA
PUTRA UNIVERSITY**

2026

ABSTRAK

Penelitian ini bertujuan untuk menganalisis faktor-faktor yang mempengaruhi harga rumah di negara bagian California dan membangun model prediksi harga menggunakan algoritma Machine Learning. Data yang digunakan bersumber dari dataset California Housing yang mencakup berbagai fitur seperti lokasi geografis (garis lintang dan bujur), rata-rata pendapatan rumah tangga, usia bangunan, jumlah kamar, serta kepadatan penduduk di suatu wilayah.

Metodologi penelitian meliputi beberapa tahap utama, diawali dengan eksplorasi data (Exploratory Data Analysis) untuk memahami distribusi variabel dan korelasi antar fitur. Tahap prapemrosesan data dilakukan dengan menangani nilai yang hilang (missing values), melakukan penyangkutan variabel kategori (one-hot encoding pada fitur `ocean_proximity`), serta pembagian data menjadi set pelatihan dan set pengujian. Model regresi linier (Linear Regression) dipilih sebagai metode dasar untuk memodelkan hubungan antara fitur-fitur independen terhadap variabel target, yaitu `median_house_value`.

Hasil analisis menunjukkan bahwa variabel rata-rata pendapatan (median income) memiliki korelasi positif yang paling signifikan terhadap harga rumah. Evaluasi model dilakukan menggunakan metrik Root Mean Squared Error (RMSE) untuk mengukur tingkat akurasi prediksi. Meskipun model regresi linier mampu menangkap tren umum dalam data, terdapat batasan dalam menangani hubungan non-linear yang kompleks. Laporan ini memberikan gambaran bagi pengembang properti maupun pembuat kebijakan dalam memahami dinamika pasar perumahan berdasarkan karakteristik demografis dan geografis di California.

DAFTAR ISI :

ABSTRAK	2
BAB I PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Rumusan Masalah	4
1.3 Tujuan Project	4
1.4 Manfaat Project	5
1.5 Batasan Masalah	5
BAB II DATA DAN METODOLOGI BIG DATA	5
2.1 Sumber Data	5
2.2 Karakteristik Data	6
2.3 Justifikasi Big Data	6
2.4 Arsitektur Pemrosesan Data	7
2.5 Tools dan Teknologi	8
BAB III DATA PREPROCESSING DAN BIG DATA PROCESSING	8
3.1 Data Loading	8
3.2 Data Cleaning	9
3.3 Data Transformation	9
3.4 Optimasi Big Data	10
BAB IV EXPLORATORY DATA ANALYSIS (EDA)	11
4.1 Statistik Deskriptif	11
4.2 Visualisasi Data (min. 10 grafik + insight)	11
4.3 Temuan Utama	12
BAB V ANALISIS AI / MACHINE LEARNING	12
5.1 Alasan Pemilihan Metode	12
5.2 Implementasi Model	12
5.3 Evaluasi Model	13
5.4 Error Analysis	14
BAB VI INSIGHT, KEPUTUSAN, DAN DAMPAK	15
6.1 Insight Berbasis Data	15
6.2 Rekomendasi	15
6.3 Dampak Potensial	16
BAB VII ETIKA, BIAS, DAN REFLEKSI AI	16
7.1 Analisis Bias Data	16
7.2 Risiko Interpretasi	17
7.3 Refleksi Penggunaan AI	18
BAB VIII KESIMPULAN DAN SARAN	18
8.1 Kesimpulan	18
8.2 Saran	19
LAMPIRAN	19
A. Struktur Dataset	19
B. Cuplikan Kode PySpark	21
C. AI Usage Log	21
D. Link GitHub dan Colab	21

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dunia investasi dan pasar modal saat ini tengah berada di persimpangan jalan akibat pesatnya perkembangan Kecerdasan Buatan (AI). Teknologi ini tidak hanya mengubah cara operasional perusahaan, tetapi juga merombak struktur tenaga kerja secara global. Berdasarkan data operasional proyeksi tahun 2030, berbagai sektor pekerjaan menunjukkan tingkat paparan AI yang signifikan. Sebagai contoh, peran teknis seperti Software Engineer dan Data Scientist memiliki indeks paparan AI yang sangat tinggi (mencapai 0.91), sementara sektor layanan seperti Retail Worker menghadapi probabilitas otomatisasi yang kritis.

Fenomena ini menciptakan volatilitas baru di pasar modal. Investor kini tidak hanya melihat laporan keuangan tradisional, tetapi juga menganalisis sejauh mana sebuah emiten mampu beradaptasi dengan gelombang otomatisasi. Perusahaan yang mampu mengintegrasikan AI untuk efisiensi biaya tenaga kerja cenderung dipandang memiliki prospek pertumbuhan tinggi (Tech Growth Factor), namun di sisi lain, risiko sosial dan pergeseran struktur pekerjaan menciptakan ketidakpastian pasar. Oleh karena itu, diperlukan analisis Big Data untuk membaca tren ini agar pelaku pasar modal dapat mengambil keputusan investasi yang lebih presisi dan antisipatif terhadap risiko otomatisasi 2030.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, permasalahan yang akan dibahas dalam proyek ini adalah: Bagaimana korelasi antara indeks paparan AI (AI Exposure Index) dengan potensi pertumbuhan teknologi (Tech Growth Factor) pada berbagai sektor industri? Sejauh mana probabilitas otomatisasi tahun 2030 memengaruhi klasifikasi risiko investasi pada emiten di pasar modal? Bagaimana tren Big Data dari komposisi keterampilan (skills) dan tingkat pendidikan tenaga kerja dapat digunakan sebagai indikator prediksi performa saham perusahaan di masa depan?

1.3 Tujuan Project

Tujuan dari pelaksanaan proyek analisis ini adalah: Memetakan sektor-sektor pekerjaan yang paling rentan terhadap otomatisasi berdasarkan data proyeksi 2030. Menganalisis dampak otomatisasi AI terhadap nilai strategis perusahaan di mata investor. Memberikan rekomendasi berbasis data mengenai sektor industri yang memiliki ketahanan (resilience) tinggi di tengah gelombang AI untuk kepentingan portofolio pasar modal.

1.4 Manfaat Project

Bagi Investor: Memberikan panduan strategis dalam memilih saham perusahaan yang memiliki fundamental adaptasi teknologi yang kuat. Bagi Perusahaan/Emiten: Menjadi bahan evaluasi dalam mengelola sumber daya manusia dan investasi teknologi guna meningkatkan kepercayaan pasar. Bagi Akademisi/Analisis: Menambah literatur mengenai penerapan analisis Big Data dalam menjembatani isu ketenagakerjaan dengan dinamika pasar modal.

1.5 Batasan Masalah

Agar penelitian tetap fokus, maka batasan masalah ditetapkan sebagai berikut: Data yang digunakan bersumber dari dataset "AI Impact on Jobs 2030" yang mencakup variabel gaji rata-rata, tingkat pendidikan, indeks paparan AI, dan probabilitas otomatisasi. Analisis pasar modal difokuskan pada pembacaan tren makro dan klasifikasi risiko berdasarkan sektor pekerjaan, bukan pada analisis teknikal harga saham harian. Proyeksi analisis dibatasi hingga tahun target 2030 sesuai dengan cakupan data yang tersedia.

BAB II

DATA DAN METODOLOGI BIG DATA

2.1 Sumber Data

Data yang digunakan dalam penelitian ini merupakan data historis saham yang berisi informasi mengenai pergerakan harga saham dalam periode waktu tertentu. Dataset ini diperoleh dari kagel.com dengan link (<https://www.kaggle.com/datasets/khushikyad001/ai-impact-onjobs2030>) sumber data pasar keuangan yang menyediakan informasi mengenai aktivitas perdagangan saham di pasar modal.

Data saham ini memiliki beberapa tipe data sebagai berikut

- Job_Title,
- Average_Salary
- Years_Experience
- Education_Level
- AI_Exposure_Index
- Tech_Growth_Factor
- Automation_Probability_2030
- Risk_Category
- Skill_1; Skill_2; Skill_3; Skill_4; Skill_5; Skill_6; Skill_7; Skill_8; Skill_9; Skill_10

Data historis saham ini digunakan untuk menganalisis pola pergerakan harga saham serta memahami dinamika pasar modal dimana perkembangan sangat pesat di sektor teknologi seperti ai dan memprediksi saham ke depannya di tahun 2030

2.2 Karakteristik Data

1. Tipe Data: Deret Waktu (Time Series)

Data ini bersifat kronologis, di mana sumbu mendatar (X) mewakili Waktu dan sumbu tegak (Y) mewakili Nilai Indeks atau Harga. Karakter utamanya adalah ketergantungan pada urutan waktu untuk melihat tren naik atau turun.

2. Volatilitas (Fluktuasi Harga)

Jika diperhatikan pada bagian tengah grafik (area berwarna merah), terdapat penurunan tajam yang menunjukkan volatilitas tinggi. Ini mencerminkan adanya sentimen pasar negatif atau respons terhadap peristiwa ekonomi tertentu pada periode tersebut.

3. Indikator Teknis

Grafik tersebut menggunakan beberapa elemen data teknis:

Candlestick/Line Chart: Menunjukkan harga pembukaan, penutupan, tertinggi, dan terendah.

Moving Average (Garis Biru/Kuning): Data rata-rata bergerak yang digunakan untuk menghaluskan fluktuasi harga guna mengidentifikasi arah tren jangka panjang.

Volume: Biasanya terdapat data volume transaksi di bagian bawah yang menunjukkan seberapa aktif perdagangan pada titik waktu tersebut.

4. Pola Tren (Trend Patterns)

Data ini memiliki karakteristik pola yang bisa diidentifikasi secara visual:

Bulish (Uptrend): Saat grafik bergerak mendaki (terlihat di sisi kanan setelah pemulihan).

Bearish (Downtrend): Saat grafik menukik tajam ke bawah.

Support & Resistance: Titik-titik terendah dan tertinggi yang menjadi batas psikologis harga.

2.3 Justifikasi Big Data

Penggunaan konsep big data dalam analisis data saham dapat dijelaskan melalui beberapa karakteristik utama big data yang dikenal sebagai 5V, yaitu:

1. Volume

Data saham memiliki volume yang besar karena mencatat transaksi perdagangan setiap hari dalam jangka waktu yang panjang.

2. Velocity

Data saham diperbarui secara cepat dan real-time selama jam perdagangan pasar modal.

3. Variety

Data saham memiliki berbagai jenis informasi seperti harga, volume transaksi, indikator teknikal, serta data fundamental perusahaan.

4. Veracity

Keakuratan data sangat penting karena data saham digunakan sebagai dasar pengambilan keputusan investasi.

5. Value

Data saham memiliki nilai yang tinggi karena dapat digunakan untuk analisis pasar, pengambilan keputusan investasi, serta prediksi pergerakan harga saham.

Berdasarkan karakteristik tersebut, analisis data saham sangat relevan untuk menggunakan pendekatan big data.

2.4 Arsitektur Pemrosesan Data

Dalam penelitian ini, arsitektur pemrosesan data dilakukan melalui beberapa tahapan utama, yaitu:

1. Data Collection (Pengumpulan Data)

Pada tahap ini dilakukan pengumpulan data historis saham dari sumber data pasar modal.

2. Data Preprocessing (Pra-pemrosesan Data)

Tahap ini meliputi proses pembersihan data (data cleaning), penghapusan data yang tidak lengkap, serta transformasi data agar siap untuk dianalisis.

3. Data Storage (Penyimpanan Data)

Data yang telah diproses kemudian disimpan dalam sistem penyimpanan data seperti database atau file dataset.

4. Data Processing (Pemrosesan Data)

Tahap ini melibatkan proses analisis data untuk mengidentifikasi pola pergerakan harga saham, tren pasar, serta hubungan antar variabel.

5. Data Visualization (Visualisasi Data)

Hasil analisis data kemudian ditampilkan dalam bentuk grafik atau diagram untuk mempermudah interpretasi data.

Arsitektur pemrosesan ini membantu dalam mengelola data saham yang besar sehingga proses analisis dapat dilakukan secara lebih efisien.

2.5 Tools dan Teknologi

Dalam proses analisis data saham berbasis big data, digunakan beberapa tools dan teknologi pendukung, antara lain:

1. Python

Python digunakan sebagai bahasa pemrograman utama dalam proses analisis data karena memiliki banyak library yang mendukung pengolahan data.

2. Pandas

Library Pandas digunakan untuk membaca, mengelola, serta melakukan analisis dataset saham.

3. NumPy

Digunakan untuk melakukan perhitungan numerik dan pengolahan data dalam skala besar.

4. Matplotlib dan Seaborn

Digunakan untuk membuat visualisasi data seperti grafik pergerakan harga saham.

5. Jupyter Notebook atau Google Colab

Digunakan sebagai lingkungan kerja untuk melakukan analisis data secara interaktif.

BAB III

DATA PREPROCESSING DAN BIG DATA PROCESSING

3.1 Data Loading

Tahap data loading merupakan proses awal dalam pengolahan data, yaitu memuat dataset saham ke dalam sistem analisis. Pada tahap ini, data historis saham yang tersimpan dalam format file seperti CSV (Comma Separated Values) diimpor ke dalam lingkungan pemrograman untuk selanjutnya diproses.

Proses data loading dilakukan menggunakan bahasa pemrograman Python dengan bantuan library Pandas yang mampu membaca dan mengelola data dalam jumlah besar secara efisien. Dataset yang dimuat berisi beberapa atribut penting seperti tanggal perdagangan, harga pembukaan (open), harga tertinggi (high), harga terendah (low), harga penutupan (close), serta volume transaksi saham.

Dengan melakukan data loading, seluruh data yang terdapat dalam file dataset dapat diakses dan dianalisis untuk tahap selanjutnya dalam proses pengolahan big data.

3.2 Data Cleaning

Tahap data cleaning merupakan proses pembersihan data untuk memastikan bahwa dataset yang digunakan dalam analisis memiliki kualitas yang baik. Data yang tidak lengkap, tidak konsisten, atau mengandung kesalahan dapat mempengaruhi hasil analisis.

Beberapa proses yang dilakukan pada tahap data cleaning antara lain:

1. Mengidentifikasi data yang hilang (missing values)

Data yang tidak memiliki nilai pada atribut tertentu akan diperiksa dan ditangani agar tidak mengganggu proses analisis.

2. Menghapus data duplikat

Data yang muncul lebih dari satu kali dalam dataset akan dihapus untuk menghindari bias dalam analisis.

3. Memeriksa konsistensi data

Pada tahap ini dilakukan pengecekan apakah nilai harga saham berada dalam rentang yang logis, misalnya harga tertinggi tidak boleh lebih kecil dari harga terendah.

4. Memperbaiki format data

Beberapa atribut seperti tanggal transaksi disesuaikan ke dalam format yang seragam agar dapat digunakan dalam analisis runtun waktu.

Melalui proses data cleaning, dataset yang digunakan menjadi lebih akurat dan siap untuk diproses lebih lanjut.

3.3 Data Transformation

Tahap data transformation merupakan proses mengubah atau menyesuaikan data agar lebih mudah dianalisis. Transformasi data dilakukan untuk meningkatkan kualitas data serta menyesuaikan format data dengan kebutuhan analisis.

Beberapa proses transformasi yang dilakukan antara lain:

1. Konversi tipe data

Beberapa atribut seperti tanggal diubah menjadi format datetime agar dapat dianalisis berdasarkan urutan waktu.

2. Normalisasi data

Nilai harga saham dapat dinormalisasi untuk mempermudah proses analisis dan perbandingan antar data.

3. Pembuatan fitur baru

Dalam analisis saham, dapat dibuat beberapa fitur tambahan seperti:

- * Perubahan harga harian
- * Persentase kenaikan atau penurunan harga saham
- * Rata-rata harga saham dalam periode tertentu

4. Pengelompokan data berdasarkan waktu

Data dapat dikelompokkan berdasarkan periode tertentu seperti harian, mingguan, atau bulanan untuk melihat tren pergerakan harga saham.

Proses transformasi ini bertujuan untuk membuat data lebih terstruktur dan siap digunakan dalam proses analisis yang lebih kompleks.

3.4 Optimasi Big Data

Tahap optimasi big data bertujuan untuk meningkatkan efisiensi dalam proses pengolahan dan analisis data yang berukuran besar. Dalam konteks analisis data saham, optimasi dilakukan agar proses pengolahan data dapat berjalan lebih cepat dan efisien.

Beberapa teknik optimasi yang dilakukan antara lain:

1. Penggunaan library pengolahan data yang efisien

Library seperti Pandas dan NumPy digunakan karena mampu mengolah data dalam jumlah besar dengan performa yang baik.

2. Pengolahan data secara terstruktur

Data diorganisasikan dalam bentuk tabel atau struktur data yang memudahkan proses pencarian dan analisis.

3. Pengurangan data yang tidak relevan

Atribut yang tidak diperlukan dalam analisis dapat dihapus untuk mengurangi beban pemrosesan data.

4. Penggunaan teknik komputasi yang efisien

Teknik seperti vectorized operations digunakan untuk mempercepat proses perhitungan dalam analisis data.

Dengan menerapkan optimasi big data, proses pengolahan data saham dapat dilakukan secara lebih efektif sehingga menghasilkan analisis yang lebih cepat dan akurat.

BAB IV

EXPLORATORY DATA ANALYSIS (EDA)

4.1 Statistik Deskriptif :

- Jumlah Data: Terdapat 3.000 entri pekerjaan dengan 18 kolom variabel.
- Gaji Rata-rata: Gaji berkisar dari nilai minimum yang rendah hingga pekerjaan dengan gaji tinggi seperti Construction Worker (\$146,216) atau Retail Worker (\$148,015).
- Pengalaman Kerja: Rata-rata pengalaman kerja dalam dataset ini bervariasi luas dari 0 hingga 29 tahun.
- Indeks Paparan AI: Memiliki rentang antara 0.0 (rendah) hingga hampir 1.0 (sangat terpapar).

4.2 Visualisasi Data (min. 10 grafik + insight)

1. Bar Chart: Rata-rata Paparan AI per Sektor Pekerjaan
 - a. Insight: Pekerjaan teknis seperti AI Engineer dan Data Scientist memiliki indeks paparan yang unik dibandingkan pekerjaan fisik.
2. Pie Chart: Distribusi Kategori Risiko
 - a. Insight: Menunjukkan proporsi pekerjaan yang masuk dalam kategori High, Medium, dan Low Risk terhadap otomatisasi 2030.
3. Scatter Plot: Hubungan Pengalaman Kerja vs Gaji
 - a. Insight: Mengidentifikasi apakah loyalitas (tahun pengalaman) berbanding lurus dengan peningkatan pendapatan di era AI.
4. Heatmap: Korelasi Antar Variabel
 - a. Insight: Terdapat korelasi antara Tech Growth Factor dengan Automation Probability.
5. Box Plot: Gaji Berdasarkan Tingkat Pendidikan
 - a. Insight: Membandingkan distribusi pendapatan antara lulusan High School, Bachelor's, Master's, dan PhD.
6. Histogram: Distribusi Probabilitas Otomatisasi 2030
 - a. Insight: Sebagian besar pekerjaan memiliki probabilitas otomatisasi yang terkonsentrasi di angka tertentu.
7. Stacked Bar Chart: Kategori Risiko Berdasarkan Pendidikan
 - a. Insight: Menilai apakah tingkat pendidikan yang lebih tinggi memberikan perlindungan terhadap risiko otomatisasi.
8. Violin Plot: Distribusi Faktor Pertumbuhan Teknologi
 - a. Insight: Melihat kepadatan data pada variabel pertumbuhan teknologi di berbagai sektor.
9. Line Chart: Tren Gaji Berdasarkan Indeks Paparan AI
 - a. Insight: Menganalisis apakah pekerjaan yang sangat terpapar AI cenderung memiliki gaji yang lebih kompetitif.
10. Bubble Chart: AI Exposure vs Automation Probability vs Gaji
 - a. Insight: Visualisasi tiga dimensi untuk melihat titik temu antara paparan teknologi, risiko kehilangan pekerjaan, dan imbalan finansial.

4.3 Temuan Utama

- Risiko Tidak Selalu Berbanding Lurus dengan Gaji: Beberapa pekerjaan dengan gaji sangat tinggi seperti Retail Worker (\$148,015) tetap memiliki kategori risiko High.
- Pendidikan Tinggi sebagai "Buffer": Pekerjaan yang memerlukan gelar PhD atau Master's sering kali memiliki Automation Probability yang lebih rendah, seperti Research Scientist (0.05).
- Variabilitas Sektor: Pekerjaan fisik seperti Construction Worker dan Security Guard menunjukkan kerentanan tinggi terhadap otomatisasi di tahun 2030 (di atas 0.80).
- Peran Pengalaman: Pengalaman kerja yang tinggi (misalnya 28 tahun) tidak menjamin rendahnya risiko jika indeks paparan AI pada jenis pekerjaan tersebut sudah tinggi.

BAB V

ANALISIS AI / MACHINE LEARNING

5.1 Alasan Pemilihan Metode

- K-Means: Digunakan untuk mengelompokkan jenis pekerjaan ke dalam kluster risiko pasar guna membantu investor mengidentifikasi sektor yang stabil dan sektor yang disruptif.
- Heatmap Korelasi : 1. Apa Fungsinya?
- Diagram ini digunakan untuk melihat seberapa kuat hubungan antara dua variabel. Angka-angka di dalam kotak menunjukkan Koefisien Korelasi, yang biasanya berkisar antara -1 hingga 1.
 - Nilai mendekati 1: Hubungan positif yang kuat (jika variabel A naik, variabel B juga naik).
 - Nilai mendekati -1: Hubungan negatif yang kuat (jika variabel A naik, variabel B turun).
 - Nilai mendekati 0: Tidak ada hubungan atau hubungan sangat lemah.

5.2 Implementasi Model

1. Scatter Plot (Kiri): Korelasi AI Exposure vs Otomasi 2030

Diagram titik-titik ini bertujuan untuk melihat persebaran data dan pengelompokan risiko.

- Sumbu X (Bawah): Menunjukkan seberapa besar sebuah pekerjaan terpapar oleh teknologi AI.
- Sumbu Y (Kiri): Menunjukkan probabilitas pekerjaan tersebut akan digantikan oleh otomatisasi pada tahun 2030.

- Warna (Kategori Risiko): Titik-titik ini dikelompokkan menjadi tiga warna untuk memudahkan klasifikasi:
 - Biru (High): Pekerjaan dengan probabilitas otomatisasi tinggi (di atas 0.7).
 - Hijau (Medium): Pekerjaan dengan risiko menengah (antara 0.3 hingga 0.7).
 - Oranye (Low): Pekerjaan yang cenderung aman atau risiko rendah (di bawah 0.3).
- Pola: Karena titik-titiknya menyebar merata seperti kotak (tidak membentuk garis miring), ini menunjukkan bahwa AI Exposure tidak selalu menjamin Probabilitas Otomasi yang tinggi dalam dataset ini—keduanya adalah faktor yang berbeda.

2. Bar Chart (Kanan): Jumlah Pekerjaan per Kategori Risiko

- Diagram batang ini berfungsi untuk menghitung volume atau distribusi data (statistik deskriptif).
- Tujuan: Memberikan jawaban cepat tentang "Berapa banyak pekerjaan yang masuk kategori terancam?".
- Interpretasi:
- Kategori Medium (hijau) memiliki jumlah pekerjaan paling banyak, mencapai lebih dari 1400 pekerjaan.
- Kategori High dan Low memiliki jumlah yang hampir setara, yaitu di kisaran 700-800 pekerjaan.

5.3 Evaluasi Model

1. Analisis Korelasi (Heatmap & Scatter Plot)

Berdasarkan Heatmap dan Scatter Plot (Paparan AI vs Otomasi):

- Korelasi Lemah: Hampir semua variabel memiliki koefisien korelasi mendekati 0 (antara -0.02 hingga 0.03). Ini menunjukkan bahwa AI Exposure Index bukan merupakan prediktor tunggal bagi Automation Probability.
- Independensi Variabel: Gaji dan pengalaman kerja juga tidak memiliki hubungan linier dengan risiko otomatisasi. Artinya, risiko pekerjaan digantikan AI tersebar di semua level gaji dan tingkat pengalaman.

2. Evaluasi Distribusi Gaji (Boxplot & Histogram)

Berdasarkan Variasi Gaji Berdasarkan Kategori Risiko:

- Rentang Gaji Serupa: Median gaji (garis tengah dalam kotak) untuk kategori risiko High, Low, dan Medium berada di level yang hampir sama (sekitar 80.000 - 90.000).

- Kesimpulan: Model menunjukkan bahwa pekerjaan berisiko tinggi terkena otomatisasi tidak terbatas pada pekerjaan berupah rendah saja; pekerjaan berupah tinggi pun memiliki variasi risiko yang serupa.

3. Pengaruh Pendidikan (Violin Plot)

Berdasarkan Distribusi Faktor Pertumbuhan Teknologi per Tingkat Pendidikan:

- Distribusi Seragam: Bentuk "biola" pada tingkat pendidikan Master's, PhD, High School, dan Bachelor's terlihat sangat mirip.
- Tech Growth Factor: Faktor pertumbuhan teknologi tersebar merata di semua tingkat pendidikan, dengan konsentrasi massa (bagian terlebar) berada di sekitar nilai 0.8 hingga 1.2.

4. Hubungan Pengalaman Kerja (Regression Plot)

Berdasarkan Hubungan Pengalaman Kerja dengan Gaji:

- Garis Regresi Horizontal: Garis merah yang mendatar menunjukkan bahwa dalam dataset ini, bertambahnya Years_Experience tidak secara signifikan meningkatkan Average_Salary.
- Sebaran Data (Noise): Titik-titik data sangat tersebar luas (scattered), yang menandakan adanya variabilitas yang tinggi atau perlunya variabel tambahan untuk menjelaskan model gaji.

5.4 Error Analysis

Lemahnya Korelasi Linier (Underfitting Potential)

Berdasarkan Heatmap dan Scatter Plot, terlihat bahwa koefisien korelasi antar variabel utama berada di angka yang sangat rendah (mendekati 0).

- Masalah: Model linier sederhana kemungkinan besar akan mengalami underfitting karena variabel independen (seperti gaji dan pengalaman) tidak memiliki hubungan garis lurus dengan risiko otomatisasi.
- Implikasi: Prediksi tidak bisa hanya mengandalkan regresi linier. Diperlukan model non-linier atau penambahan variabel baru (fitur) yang lebih spesifik terhadap sektor industri tertentu.

2. Sebaran Data yang Homogen (High Variance)

Pada grafik Regression Plot antara Pengalaman Kerja dan Gaji, terlihat sebaran data yang sangat luas namun garis regresinya datar.

- Masalah: Terdapat variansi yang sangat tinggi di setiap titik pengalaman kerja. Artinya, seseorang dengan pengalaman 5 tahun bisa memiliki gaji yang sama dengan yang berpengalaman 25 tahun dalam dataset ini.
- Kesalahan Prediksi: Model akan sulit menentukan nilai pasti (prediksi gaji) karena "noise" atau gangguan data yang terlalu besar, sehingga tingkat Mean Absolute Error (MAE) kemungkinan akan tinggi.

BAB VI

INSIGHT, KEPUTUSAN, DAN DAMPAK

6.1 Insight Berbasis Data

Berdasarkan analisis dataset AI Impact on Jobs 2030, ditemukan beberapa pola krusial yang menggambarkan masa depan lanskap industri di pasar modal:

- **Polaritas Risiko Industri:** Terdapat dikotomi yang jelas antara sektor yang memiliki ketahanan tinggi terhadap AI dengan sektor yang sangat rentan. Pekerjaan seperti Doctor dan Research Scientist memiliki probabilitas otomatisasi yang sangat rendah (sekitar 0.05 - 0.11), yang menunjukkan bahwa emiten di sektor kesehatan dan bioteknologi memiliki stabilitas fundamental jangka panjang.
- **Kerentanan Sektor Operasional dan Logistik:** Sektor-sektor dengan ketergantungan tinggi pada tenaga kerja fisik dan rutin, seperti Retail Worker (probabilitas otomatisasi hingga 0.93) dan Truck Driver (mencapai 0.92), menghadapi risiko disrupsi operasional yang masif. Investor harus mewaspadai emiten di sektor ini yang tidak segera melakukan transformasi digital.
- **Paradoks Peran Teknologi:** Menariknya, peran teknis seperti Software Engineer dan Data Scientist berada dalam kategori risiko "Medium" dengan probabilitas otomatisasi antara 0.40 hingga 0.70. Hal ini mengindikasikan bahwa AI mulai mampu mengotomatisasi tugas-tugas teknis standar, sehingga nilai perusahaan teknologi ke depan akan bergantung pada inovasi tingkat lanjut, bukan sekadar skalabilitas SDM teknis.
- **Korelasi Gaji dan Paparan AI:** Tidak selamanya pekerjaan dengan gaji tinggi aman dari AI. Data menunjukkan beberapa manajer pemasaran (Marketing Manager) dan analis keuangan (Financial Analyst) memiliki AI Exposure Index yang cukup tinggi (di atas 0.50), yang berarti biaya operasional emiten di sektor jasa keuangan berpotensi menurun drastis melalui efisiensi AI.

6.2 Rekomendasi

Dari insight di atas, berikut adalah rekomendasi strategis bagi para pengambil keputusan di pasar modal:

1. **Strategi Portofolio "High Resilience":** Prioritaskan penempatan modal pada emiten di sektor yang memiliki Risk Category "Low", seperti layanan kesehatan canggih dan riset ilmiah, karena sektor ini paling sulit digantikan oleh AI hingga 2030.

2. Seleksi Emiten Adaptif: Investor disarankan memilih perusahaan di sektor retail dan logistik yang secara agresif mengalokasikan Capital Expenditure (CapEx) untuk teknologi otomatisasi guna memitigasi risiko tinggi pada probabilitas otomatisasi 2030.
3. Fokus pada Nilai Tambah Manusia: Dalam mengevaluasi emiten sektor kreatif dan manajerial, pilih perusahaan yang menekankan pada high-level strategy dan kreativitas, mengingat AI mulai mengambil alih peran teknis menengah.

6.3 Dampak Potensial

Implementasi analisis Big Data ini dalam pengambilan keputusan investasi akan memberikan dampak sebagai berikut:

- Efisiensi Alokasi Modal: Investor dapat menghindari "perangkap nilai" (value trap) pada perusahaan-perusahaan yang terlihat murah namun memiliki risiko keusangan tenaga kerja yang tinggi akibat AI.
- Akselerasi Transformasi Emiten: Tekanan dari pasar modal (investor) akan memaksa perusahaan-perusahaan dengan risiko otomatisasi tinggi untuk segera mengadopsi AI, yang pada akhirnya meningkatkan produktivitas ekonomi secara makro.
- Stabilitas Pasar Modal: Dengan pembacaan tren yang lebih presisi terhadap gelombang otomatisasi, volatilitas pasar akibat sentimen AI dapat lebih terukur, memungkinkan terciptanya pasar modal yang lebih dewasa dalam merespons perkembangan teknologi.

BAB VII

ETIKA, BIAS, DAN REFLEKSI AI

7.1 Analisis Bias Data

Dalam analisis big data mengenai dampak Artificial Intelligence (AI) terhadap pekerjaan hingga tahun 2030, penting untuk memperhatikan kemungkinan adanya bias pada data yang digunakan. Bias data dapat mempengaruhi hasil analisis dan interpretasi sehingga dapat menghasilkan kesimpulan yang kurang objektif.

Dataset yang digunakan pada penelitian ini terdiri dari 3000 data pekerjaan dengan 20 jenis profesi berbeda, serta berbagai variabel seperti Average Salary, Years Experience, Education Level, AI Exposure Index, Automation Probability 2030, dan Risk Category. Berdasarkan eksplorasi data, terdapat beberapa potensi bias yang dapat diidentifikasi.

Pertama adalah bias distribusi kategori risiko pekerjaan. Dari total data yang tersedia, kategori risiko pekerjaan terhadap otomatisasi didominasi oleh

kategori Medium Risk, yaitu sebanyak 1521 data. Sementara itu kategori lainnya seperti High Risk dan Low Risk memiliki jumlah yang lebih sedikit. Ketidakseimbangan distribusi ini dapat mempengaruhi model analisis sehingga hasil prediksi lebih condong terhadap kategori yang paling banyak muncul.

Kedua adalah bias tingkat pendidikan. Data menunjukkan bahwa kategori pendidikan yang paling sering muncul adalah High School dengan 784 data. Hal ini menunjukkan bahwa sebagian besar pekerjaan dalam dataset berasal dari kelompok pendidikan menengah. Kondisi ini dapat menyebabkan hasil analisis lebih merepresentasikan kondisi pekerja dengan pendidikan menengah dibandingkan dengan pekerja yang memiliki pendidikan tinggi seperti Bachelor, Master, atau PhD.

Ketiga adalah bias representasi jenis pekerjaan. Walaupun terdapat 20 jenis pekerjaan, beberapa pekerjaan memiliki jumlah data yang lebih banyak dibandingkan yang lain. Sebagai contoh, pekerjaan Software Engineer memiliki sekitar 175 data, sehingga analisis yang dilakukan dapat lebih banyak mencerminkan karakteristik pekerjaan di bidang teknologi dibandingkan sektor pekerjaan lainnya.

7.2 Risiko Interpretasi

Selain bias pada data, terdapat juga risiko kesalahan dalam interpretasi hasil analisis AI. Risiko interpretasi dapat muncul ketika hasil analisis data dianggap sebagai fakta mutlak tanpa mempertimbangkan konteks sosial, ekonomi, maupun teknologi yang lebih luas.

Salah satu risiko interpretasi adalah penyederhanaan terhadap probabilitas otomatisasi pekerjaan. Pada dataset ini terdapat variabel Automation Probability 2030 dengan nilai antara 0.05 hingga 0.95, dengan rata-rata sekitar 0.50. Nilai tersebut menunjukkan kemungkinan suatu pekerjaan akan terdampak oleh otomatisasi pada masa depan. Namun nilai probabilitas ini tidak dapat langsung diartikan bahwa pekerjaan tersebut pasti akan hilang, melainkan hanya menunjukkan tingkat kerentanan terhadap otomatisasi.

Contohnya, pekerjaan seperti Security Guard memiliki probabilitas otomatisasi yang relatif tinggi (sekitar 0.85 pada salah satu data contoh), sedangkan pekerjaan seperti Research Scientist memiliki probabilitas yang jauh lebih rendah (sekitar 0.05). Meskipun demikian, kondisi tersebut tidak berarti bahwa pekerjaan dengan probabilitas tinggi akan sepenuhnya digantikan oleh AI, karena masih terdapat faktor lain seperti regulasi, kebutuhan manusia, dan perkembangan teknologi yang mempengaruhi proses tersebut.

7.3 Refleksi Penggunaan AI

Penggunaan Artificial Intelligence dalam analisis big data memberikan banyak manfaat, terutama dalam memahami pola dan tren yang sulit dianalisis secara manual. Dalam penelitian ini, AI digunakan untuk menganalisis kemungkinan dampak otomatisasi terhadap berbagai jenis pekerjaan hingga tahun 2030.

Berdasarkan data yang dianalisis, dapat dilihat bahwa tingkat dampak AI terhadap pekerjaan sangat bervariasi. Beberapa pekerjaan memiliki probabilitas otomatisasi yang tinggi, sementara pekerjaan lainnya memiliki risiko yang lebih rendah karena memerlukan kreativitas, analisis kompleks, atau keahlian khusus yang sulit digantikan oleh mesin.

Refleksi penting dari penggunaan AI dalam penelitian ini adalah bahwa teknologi AI seharusnya tidak hanya dipandang sebagai ancaman bagi tenaga kerja, tetapi juga sebagai alat untuk meningkatkan produktivitas dan efisiensi kerja. Dengan memanfaatkan AI secara tepat, manusia dapat berkolaborasi dengan teknologi untuk menciptakan jenis pekerjaan baru serta meningkatkan kualitas pekerjaan yang ada.

BAB VIII

KESIMPULAN DAN SARAN

8.1 Kesimpulan

Berdasarkan hasil analisis Big Data terhadap dataset dampak AI tahun 2030, dapat disimpulkan bahwa:

- Ketidakselarasan Korelasi Linier: Indeks paparan AI (AI Exposure Index) bukan merupakan prediktor tunggal bagi probabilitas otomatisasi, karena hubungan antar variabel utama cenderung lemah dan tidak bersifat linier.
- Risiko Melintas Level Ekonomi: Risiko otomatisasi tidak terbatas pada pekerjaan berupah rendah; pekerjaan dengan gaji tinggi pun memiliki variasi risiko yang serupa, menunjukkan bahwa stabilitas finansial tidak menjamin keamanan dari disrupsi teknologi.
- Pendidikan sebagai Pelindung: Tingkat pendidikan tinggi, khususnya gelar Master dan PhD, terbukti menjadi faktor penghambat (buffer) yang signifikan terhadap tingginya probabilitas otomatisasi.
- Polaritas Sektor: Terdapat perbedaan mencolok antara sektor kesehatan/riset yang memiliki ketahanan tinggi dengan sektor retail/logistik yang sangat rentan terhadap otomatisasi masif mencapai angka di atas 0.90.
- Implikasi Pasar Modal: Investor perlu melakukan seleksi emiten yang adaptif dan memiliki strategi transformasi digital yang kuat untuk menghindari "perangkap nilai" pada perusahaan dengan ketergantungan tenaga kerja rutin yang tinggi.

8.2 Saran

Berdasarkan temuan penelitian, saran-saran yang dapat diajukan adalah sebagai berikut:

- Bagi Investor: Disarankan untuk memprioritaskan alokasi portofolio pada sektor-sektor dengan kategori risiko rendah (Low Risk) seperti layanan kesehatan canggih dan riset ilmiah guna menjaga stabilitas fundamental jangka panjang.
- Bagi Perusahaan: Emiten di sektor operasional dan logistik harus secara agresif mengalokasikan belanja modal (CapEx) untuk integrasi teknologi AI guna memitigasi risiko disrupsi tenaga kerja sebelum tahun 2030.
- Bagi Pengembangan Model: Untuk penelitian selanjutnya, disarankan menggunakan model analisis non-linier atau menambahkan variabel spesifik sektor industri untuk mengatasi masalah underfitting dan noise data yang tinggi pada model linier sederhana.
- Bagi Tenaga Kerja: Diperlukan peningkatan keterampilan (upskilling) yang fokus pada kreativitas dan strategi tingkat tinggi, mengingat AI mulai mampu mengotomatisasi tugas-tugas teknis standar di bidang perangkat lunak dan analisis data.

LAMPIRAN

A. Struktur Dataset

No	Nama Kolom	Tipe Data	Deskripsi
1	Job_Title	String	Nama pekerjaan atau profesi
2	Average_Salary	Integer	Rata-rata gaji pekerjaan
3	Years_Experience	Integer	Jumlah pengalaman kerja yang dimiliki
4	Education_Level	String	Tingkat pendidikan pekerja (High School, Master's, PhD, dll)
5	AI_Exposure_Index	Float	Indeks tingkat paparan pekerjaan terhadap teknologi AI
6	Tech_Growth_Factor	Float	Faktor pertumbuhan teknologi pada bidang pekerjaan tersebut

7	Automation_Probability_2030	Float	Probabilitas pekerjaan akan terotomatisasi pada tahun 2030
8	Risk_Category	String	Kategori risiko otomatisasi (Low, Medium, High)
9	Skill_1	Float	Nilai tingkat keterampilan pertama
10	Skill_2	Float	Nilai tingkat keterampilan kedua
11	Skill_3	Float	Nilai tingkat keterampilan ketiga
12	Skill_4	Float	Nilai tingkat keterampilan keempat
13	Skill_5	Float	Nilai tingkat keterampilan kelima
14	Skill_6	Float	Nilai tingkat keterampilan keenam
15	Skill_7	Float	Nilai tingkat keterampilan ketujuh
16	Skill_8	Float	Nilai tingkat keterampilan kedelapan
17	Skill_9	Float	Nilai tingkat keterampilan kesembilan
18	Skill_10	Float	Nilai tingkat keterampilan kesepuluh

B. Cuplikan Kode PySpark

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Membaca Data
# Menggunakan sep=';' karena file CSV kamu menggunakan titik koma sebagai pemisah
df = pd.read_csv('AI_Impact_on_Jobs_2030.csv', sep=';')

# 2. Inspeksi Awal
print("--- 5 Data Teratas ---")
print(df.head())
print("\n--- Info Data ---")
print(df.info())

# 3. Analisis Statistik Sederhana
# Melihat rata-rata probabilitas otomasi berdasarkan tingkat pendidikan
education_analysis = df.groupby('Education_Level')['Automation_Probability_2030'].mean().sort_values()
print("\n--- Rata-rata Probabilitas Otomasi per Tingkat Pendidikan ---")
print(education_analysis)

# 4. Visualisasi
plt.figure(figsize=(12, 6))

# Plot A: Hubungan AI Exposure dengan Probabilitas Otomasi
plt.subplot(1, 2, 1)
sns.scatterplot(data=df, x='AI_Exposure_Index', y='Automation_Probability_2030', hue='Risk_Category')
plt.title('Korelasi AI Exposure vs Otomasi 2030')

# Plot B: Distribusi Risk Category
plt.subplot(1, 2, 2)
sns.countplot(data=df, x='Risk_Category', palette='viridis')
plt.title('Jumlah Pekerjaan per Kategori Risiko')

plt.tight_layout()
plt.show()

# 5. Mencari Top 5 Pekerjaan dengan Gaji Tertinggi namun Risiko Otomasi Rendah
high_value_jobs = df[(df['Automation_Probability_2030'] < 0.3) & (df['Average_Salary'] > 100000)]
print("\n--- Rekomendasi Pekerjaan Aman (Gaji Tinggi, Otomasi Rendah) ---")
print(high_value_jobs[['Job_Title', 'Average_Salary', 'Automation_Probability_2030']].head())
```

C. AI Usage Log

Tahap	Aktivitas	Perat AI
1	Menganalisis dataset CSV	AI membantu membaca dan memahami struktur data
2	Identifikasi kolom dan tipe data	AI membantu mengklasifikasikan atribut dataset
3	Pembuatan kode PySpark	AI membantu menghasilkan contoh kode pemrosesan data
4	Penyusunan laporan	AI membantu menyusun deskripsi dataset secara sistematis

D. Link Colab :

https://colab.research.google.com/drive/14CtBVBsR5YDKi92y_D2H6HRbz3zsujxo#scrollTo=BpF3cgwOpBJg